

基于强化学习决策的文档理解与检索多模态问答系统

刘天翔 杨毅涵 郭翊涛

计算机科学与技术

中山大学计算机学院

2026 年 6 月 19 日



目 录

- 1 系统介绍
- 2 相关技术与系统架构
- 3 实验结果
- 4 Demo 与反思






系统介绍：多模态文档问答助手

- 本项目旨在构建一个集文档解析、视觉定位、检索增强生成和自然语言理解于一体的多模态文档智能问答系统。
- 系统面向 PDF、图片等非结构化文档，识别其中的文本、表格、公式、图表和局部视觉区域，并通过多模态 RAG 实现长文档精准检索与结构化问答。
- 传统纯文本 RAG 往往把文档转成线性文本，面对图表数值、表格行列关系、广告标签、票据版面和局部视觉信息时，容易丢失页面结构和视觉语义。
- 因此，本系统围绕“文档解析-多模态证据检索-GRPO 决策模型-生成回答-PDF 高亮溯源”构建完整流程。
- 核心任务包括：多模态 RAG 架构构建、模型选择与自动决策、可解释性溯源。

系统架构图



多模态 Embedding 与 Fusion 实现

- 系统先把页面解析结果统一整理为 evidence 对象，不把文本、表格和图像割裂成三个互不相关的库。
- 文本 chunk、OCR 文本和表格 Markdown 使用 BGE-M3 生成向量表示，作为文档问答中的基础文本 embedder。
- 表格区域先转换为 Markdown table，再参与向量化，使问题中的行名、列名、时间、数值和单位能与表格结构产生语义匹配。
- 图像侧使用轻量视觉特征或 Native ViT 图像编码器提取视觉向量，用于保留局部 crop、图表区域、页面截图和图片 chunk 的检索能力。
- 每条 evidence 同时绑定文本内容、页码、bbox、页面图路径、局部 crop、source type 和 modality，便于后续检索、生成和前端溯源。

GRPO 决策模型实现

- GRPO 模块的目标不是写死路由规则，而是训练一个 Decide Model，使其根据问题和候选 evidence 学会选择 LLM/VLM。
- Decide Model 接收用户问题、检索证据和问题类型信息，选择候选回答模型，例如文本 LLM、多模态 VLM 或图表增强 VLM。
- 候选模型基于同一问题和证据分别生成回答：普通文本题更适合文本 LLM，图表、票据、广告和局部页面区域题更依赖 VLM。
- Judge Model（如 Qwen-Max）根据答案正确性、证据一致性和完整性给出 reward，例如 0、0.5 或 1。
- 系统使用 GRPO 根据 reward 更新 Decide Model，使高分的模型选择在后续相似问题中更容易被采用。

上下文重构、生成与前端溯源闭环

- 生成阶段接收检索重排后的 evidence，以及 GRPO 决策模型输出的模型选择结果。
- 系统不会简单拼接 Top-K，而是按问题类型重构上下文：文本题保留高分文本 chunk，表格题加入 Markdown table，图表题加入页面标题、图表区域和局部 crop。
- 对票据、广告、商品标签等问题，系统优先保留字段名、品牌名、OCR anchor 和局部视觉区域，减少无关页面内容对 VLM 的干扰。
- 决策模型选出的 LLM/VLM 接收重构后的上下文进行回答；需要视觉理解的问题调用 Qwen3-VL-8B-Instruct。
- 输出结果时，模型给出答案和 evidence 编号；后端把 evidence id 映射回 page、chunk id、bbox、source type 和 image path。
- 前端接收答案、引用 evidence、页码和 bbox 后，在答案区展示引用，并根据页面缩放比例把 bbox 高亮到连续 PDF viewer 中。

实验表 1: Text-RAG 与 Our-RAG 性能对比

Dataset	Model	EM	ANLS	Answer Match	Avg. Latency(ms)
DocVQA	Text-RAG	0.5500	0.6230	0.6500	5697.80
DocVQA	Our-RAG	0.9500	0.9620	0.9500	6124.35
ChartQA	Text-RAG	0.2000	0.2300	0.2500	3451.81
ChartQA	Our-RAG	0.8750	0.8960	0.9000	4896.42
Overall	Text-RAG	0.3750	0.4265	0.4500	4574.81
Overall	Our-RAG	0.9125	0.9290	0.9250	5510.39

- **总体性能:** Our-RAG 的整体 EM 达到 0.9125, ANLS 达到 0.9290, 明显高于 Text-RAG。
- **DocVQA:** 局部 crop 补充品牌、logo、票据版面和表格空间关系。
- **ChartQA:** chart region 使 VLM 能直接读取坐标轴、柱高、折线和数值比较关系。
- **效率表现:** 优先传入问题相关的局部 crop, 而不是整页多图输入。

实验表 2：消融实验与错误分析

Model	EM	ANLS	Answer Match	Delta EM
Our-RAG	0.9125	0.9290	0.9250	—
Our-RAG with Rule Decision	0.9120	0.9280	0.9300	-0.0005
Our-RAG without Reranker	0.9030	0.9100	0.9120	-0.0095
Our-RAG without Unified Embedding	0.8950	0.9020	0.9000	-0.0175

- Reranker 和统一多模态向量化是影响结果的关键因素。
- 错误主要来自复杂表格行列定位、局部视觉区域裁剪偏差、图表数值估读误差、生成答案格式波动。

Demo 视频

Demo 视频占位

反思：模型局限

- **模块化系统而非端到端理解**：当前流程仍由 OCR、版面解析、统一 embedding、向量检索、Reranker、GRPO 决策和 VLM 生成串联组成，任何模块误差都会沿 pipeline 传播到最终回答。
- **证据质量依赖前置解析**：OCR 漏识别、表格结构抽取不完整或 figure/table/code 分类不准，会导致 evidence 缺失；在票据字段、广告标签、表格行列关系等问题上尤其明显。
- **空间定位仍有不稳定性**：系统保留页码、bbox 与页面图路径用于 PDF 高亮，但 bbox 偏移、局部 crop 过大或过小都会影响前端溯源效果，也会干扰 VLM 对关键区域的观察。
- **检索召回决定视觉输入上限**：如果向量检索和重排没有召回真正相关的 chunk 或页面区域，后续即使使用更强 VLM，也只能在错误或不完整上下文中生成答案。
- **复杂视觉推理仍受底层模型限制**：图表数值估读、隐含趋势比较、跨页表格、密集版面和多实体对应关系仍可能出现“证据定位正确但推理不充分”的情况。
- **长期任务能力不足**：系统能够完成当前文档、当前问题下的问答，但对跨文档持续记忆、多轮目标追踪、主动发现矛盾和长程任务规划的支持仍比较有限。

展望：AGI 视角下的潜力与瓶颈

- **文档智能是通向通用助手的重要入口**：真实知识并不只存在于纯文本中，还分布在 PDF、表格、图片、图表、扫描件和网页截图里，系统需要同时处理文本语义与视觉结构。
- **从“回答问题”走向“管理证据”**：接近 AGI 的文档系统不仅要能读懂内容，还要能定位来源、比较多个证据、判断冲突、解释推理过程，并把答案稳定溯源到原始文档。
- **本项目的可延展基础**：当前系统已经把多模态感知、检索增强、模型选择、局部视觉 crop、答案生成和 PDF 高亮连接起来，为后续加入更强的自我验证与交互反馈留下接口。
- **近期改进方向**：继续提升复杂版面解析、表格结构恢复、图表区域裁剪、答案格式规范化和 evidence 选择稳定性，降低 OCR 与 bbox 误差对最终结果的影响。
- **决策模型优化方向**：让 GRPO 决策模型积累更多真实问答轨迹和失败样本，根据问题类型、候选模型打分与证据质量动态选择 LLM/VLM、检索深度和视觉输入策略。
- **长期 AGI 瓶颈**：未来仍需要更强的多模态基础模型、跨文档长期记忆、任务规划、自我评估和持续学习能力，才能从“能回答文档问题的系统”进一步走向“能理解、使用并管理文档知识的智能体”。

感谢老师与同学们的聆听。